

Italia sismica: una storia di terremoti

Arcangelo Franco, *Digital Humanities*, 584174, *University of Pisa*;
Nicola Pastorelli, *Digital Humanities*, 656431, *University of Pisa*

May 29, 2025

Abstract. *Il presente lavoro analizza la sismicità del territorio italiano attraverso un approccio integrato di Data Journalism e modellazione predittiva. Dopo aver sviluppato un sistema modulare per l'acquisizione automatizzata dei dati sismici forniti dall'INGV, sono state realizzate numerose visualizzazioni per esplorare l'impatto demografico, socio-economico e geografico degli eventi sismici più rilevanti. Successivamente, è stato progettato un modello predittivo per stimare la magnitudo potenziale dei terremoti sulla base di caratteristiche geospaziali, temporali e dinamiche, sfruttando tecniche avanzate di machine learning. Il modello è stato addestrato sul dataset storico raccolto dall'INGV, processato successivamente per essere validato e integrato in un sistema di previsione pronto per l'inferenza su nuovi dati.*

1. Acquisizione sistematica dei dati sismologici

L'osservazione e l'analisi dell'attività sismica costituiscono strumenti essenziali per comprendere i fenomeni geodinamici, valutare il rischio sismico e definire strategie efficaci di prevenzione e mitigazione. In Italia, il principale riferimento istituzionale per la raccolta e la diffusione dei dati sismici è rappresentato dall'**Istituto Nazionale di Geofisica e Vulcanologia** (INGV), che rende disponibile un ricco archivio di eventi sismici attraverso API pubbliche.

Per sfruttare appieno queste risorse in modo continuativo, efficiente e automatizzato, è stato sviluppato un sistema software modulare, strutturato secondo i principi della *programmazione orientata agli oggetti* (OOP). Tale architettura è stata progettata per garantire flessibilità, facilità di manutenzione e testabilità, e si articola in tre componenti principali: un client per l'interazione con l'API, un gestore della persistenza dei dati e un orchestratore che governa l'intero flusso operativo.

1.1. Interazione con l'API (ApiClient)

La componente in oggetto è deputata alla gestione della comunicazione diretta con i servizi web esposti dall'INGV. È stata concepita per astrarre e incapsulare le complessità associate alla formulazione delle richieste *HTTP*, alla configurazione dei parametri di interrogazione (inclusi intervalli temporali, soglie di magnitudo e coordinate geografiche), nonché alla ricezione e al *parsing* delle risposte restituite dai servizi remoti. Il *client* implementa meccanismi robusti per la gestione dei timeout e per l'identificazione e propagazione degli errori HTTP, tramite il sollevamento di eccezioni specifiche, progettate per essere intercettate e gestite nei livelli superiori dell'architettura applicativa. Un aspetto di rilievo è rappresentato dalla gestione della paginazione, implementata mediante l'utilizzo coordinato dei parametri *offset* e *limit*, al fine di consentire un recupero progressivo e controllato dei dati, in conformità con le *policy* del fornitore delle API e in un'ottica di ottimizzazione delle risorse di rete e calcolo.

1.2. Gestione della persistenza dei dati (DataManager)

La componente è incaricata della persistenza dei dati acquisiti, con l'obiettivo di garantire durabilità, integrità e continuità del processo di raccolta. Attualmente, il sistema è configurato per archiviare i dati in formato CSV (*Comma-Separated Values*), una soluzione testuale semplice, interoperabile e ampiamente supportata. In fase di avvio, il modulo effettua una verifica sulla presenza di un file di output preesistente: qualora rilevato, esso viene caricato al fine di ricostruire lo stato precedente e determinare il punto di ripresa dell'acquisizione (*offset*). Tale funzionalità risulta essenziale per abilitare modalità di acquisizione incrementale e per garantire resilienza operativa in presenza di interruzioni o arresti anomali del sistema. Ogni nuovo blocco di dati ricevuto viene accodato ai record già presenti e l'intero *dataset* viene

riscritto su disco, assicurando che lo stato corrente dell'acquisizione sia sempre persistito. L'impiego della libreria *pandas* per le operazioni di manipolazione e salvataggio dei dati fornisce un elevato livello di efficienza, flessibilità e robustezza computazionale.

1.3. Coordinamento delle operazioni (Fetcher)

La componente denominata *Fetcher* costituisce il nucleo logico e operativo del sistema, svolgendo il ruolo di coordinatore tra i moduli di comunicazione e di persistenza. In fase di inizializzazione, essa provvede all'attivazione del *client API* e del gestore della persistenza (*DataManager*), determinando l'offset iniziale sulla base dello stato delle acquisizioni precedentemente salvate. Successivamente, avvia un ciclo iterativo di interrogazioni all'*endpoint* dell'INGV, tipicamente ricevendo i dati in formato **GeoJSON**.

Per ciascun blocco di dati ricevuto, il *Fetcher* attiva una routine di elaborazione interna che ha il compito di estrarre le informazioni sismologiche rilevanti — quali *timestamp*, magnitudo, località epicentrale, profondità e coordinate geografiche — e di normalizzarle in una struttura dati omogenea. I record così strutturati vengono quindi trasmessi al *DataManager* per la persistenza su disco.

Il ciclo di acquisizione prosegue in maniera incrementale, aggiornando progressivamente l'*offset*, fino al momento in cui l'API non restituisce più nuovi eventi. Il *Fetcher* implementa inoltre un meccanismo di *throttling*, introducendo un ritardo configurabile tra le richieste successive, al fine di evitare il sovraccarico dei server remoti. È altresì dotato di una gestione robusta delle eccezioni, finalizzata a rilevare e trattare errori di rete, timeout o risposte anomale da parte dell'API. In prospettiva evolutiva, il design del modulo prevede l'integrazione di strategie di *retry* automatizzato per aumentare l'affidabilità del processo in scenari di errore transitorio.

1.4. Flusso operativo e gestione della paginazione

Una volta completata la configurazione iniziale, il processo di acquisizione viene avviato dal modulo orchestratore (*Fetcher*), il quale esegue come prima operazione la determinazione dell'*offset* iniziale, ovvero il numero di record già presenti nel file di output. Tale informazione, fornita dal *DataManager*, consente al sistema di evitare la duplicazione dei dati e di riprendere l'acquisizione esattamente dal punto di interruzione in caso di esecuzioni successive o malfunzionamenti. Il *Fetcher* entra quindi in un ciclo iterativo strutturato nelle seguenti fasi operative:

1. Viene inviata una richiesta all'API (*ApiClient*) utilizzando l'*offset* corrente e un limite predefinito di eventi per chiamata (ad esempio, 1000 record). Questo meccanismo di paginazione è fondamentale per gestire *dataset* di grandi dimensioni, evitando il superamento delle soglie imposte dall'API e garantendo l'efficienza nell'uso delle risorse locali;
2. La risposta restituita dall'API, tipicamente in formato *GeoJSON*, viene analizzata. In assenza di nuovi eventi, il ciclo termina, indicando il completamento dell'acquisizione per i parametri specificati;
3. Gli eventi sismici ricevuti vengono processati: le informazioni salienti (*timestamp*, magnitudo, localizzazione epicentrale, profondità, coordinate geografiche) sono estratte e normalizzate in una struttura dati uniforme;
4. I record così strutturati sono trasmessi al *DataManager*, che provvede al loro salvataggio persistente nel file CSV di output;
5. L'*offset* viene aggiornato in base al numero effettivo di eventi elaborati, oppure in funzione del limite utilizzato per la richiesta;
6. Viene introdotto un ritardo programmato tra le iterazioni successive, al fine di rispettare le politiche di utilizzo dell'API e prevenire il sovraccarico dei server remoti.

Durante l'intero processo, il sistema fornisce un *feedback* informativo in tempo reale, riportando l'*offset* corrente, il numero di nuovi eventi scaricati e il totale cumulativo, al fine di garantire trasparenza e tracciabilità dell'avanzamento dell'acquisizione.

2. Visualizzazione analitica dei dati sismici italiani

La rappresentazione visiva dei dati sismici costituisce uno strumento analitico imprescindibile per la comprensione approfondita della sismicità di un territorio e dei suoi molteplici impatti, di natura geografica, demografica, economica e infrastrutturale. Le visualizzazioni presentate in questa sezione forniscono una panoramica integrata e quantitativamente fondata dei fenomeni sismici in Italia, articolandosi su più dimensioni analitiche: dagli effetti diretti e indiretti sulla popolazione e sull'economia, alla distribuzione spaziale e temporale degli eventi, fino alla localizzazione e copertura delle reti di monitoraggio. Tali rappresentazioni facilitano l'interpretazione dei dati, promuovendo una visione sistemica dei rischi sismici e delle relative implicazioni per la pianificazione territoriale e la gestione dell'emergenza.

2.1. Impatto demografico dei principali eventi sismici

La Figura 1 mette in evidenza l'impatto umano dei principali terremoti che hanno colpito l'Italia in epoca recente. I dati sono organizzati in tre grafici a barre distinti, ciascuno dedicato a una specifica categoria: vittime, feriti e sfollati. Il terremoto dell'Irpinia del 1980 emerge come l'evento più drammatico in termini di perdite umane, registrando il numero più elevato di vittime e feriti. Anche sul piano degli sfollati, lo stesso evento si colloca in cima alla classifica, seguito dal sisma dell'Abruzzo del 2009 e da quello del Centro Italia del 2016. Tali numeri mettono in luce la vulnerabilità delle comunità italiane, soprattutto nelle aree con un patrimonio abitativo fragile e densamente popolato.




Figure 1. Costi Demografici dei Territori in Italia

2.2. Conseguenze socio-economiche indirette

La Figura 2 analizza le ripercussioni a medio e lungo termine di tre eventi sismici storici: Belice 1968, Friuli 1976 e Irpinia 1980. Vengono considerate quattro dimensioni chiave: *Prodotto Interno Lordo* (PIL) territoriale, tasso di disoccupazione, fenomeno dello spopolamento e perdita di beni culturali. Il Belice e l'Irpinia mostrano un impatto fortemente negativo sul PIL, mentre il Friuli registra un incremento, probabilmente legato agli investimenti pubblici per la ricostruzione. Tutte le aree evidenziano un aumento della disoccupazione e un significativo spopolamento. Particolarmente allarmante è la perdita di beni culturali, che risulta elevata per tutti e tre i territori, sottolineando quanto il patrimonio storico-artistico italiano sia esposto e difficile da recuperare dopo eventi di tale portata.




Figure 2. Costi Indiretti dei Territori in Italia - Variazioni Percentuali

2.3. Distribuzione spaziale della sismicità: densità per regione

La Figura 3 offre una visualizzazione normalizzata della frequenza sismica, espressa in termini di numero di terremoti per chilometro quadrato. Le regioni più colpite risultano essere Umbria, Marche, Abruzzo e Lazio, evidenziando una marcata concentrazione lungo la dorsale appenninica. Questo tipo di rappresentazione è particolarmente utile per individuare le aree ad alta pericolosità intrinseca, indipendentemente dalla loro estensione, e costituisce un riferimento prezioso per la pianificazione di politiche di prevenzione.




Figure 3. Densità di Terremoti per Regione

2.4. Caratterizzazione dell'intensità sismica: magnitudo media

Le Figure 4 e 5 analizzano la magnitudo media degli eventi sismici, rispettivamente per macro-area geografica e per decennio. La Figura 4 confronta la "Magnitudo Media" registrata nelle macro-aree Nord, Sud e Centro Italia. Sebbene le differenze possano non essere macroscopicamente ampie, questa analisi permette di investigare se esistano tendenze sistematiche nell'energia rilasciata mediamente dai terremoti nelle diverse porzioni del paese. La Figura 5 traccia l'andamento della "Magnitudo Media" attraverso quattro decenni, dal 1985-1994 al 2025-2024. Il grafico lineare mostra una tendenza alla diminuzione della magnitudo media degli eventi registrati nei decenni più recenti. Questa osservazione è strettamente correlata all'aumento della sensibilità della rete di monitoraggio, capace di rilevare un numero maggiore di eventi di bassa magnitudo che abbassano la media complessiva.




Figure 4. Magnitudo Media per Area




Figure 5. Magnitudo Media per Decennio

2.5. Infrastruttura di monitoraggio sismico nazionale

La Figura 6 mostra la distribuzione delle stazioni di rilevamento sismico sul territorio italiano, distinguendo tra quelle appartenenti alla rete INGV e quelle gestite da altre reti. La mappa evidenzia una copertura capillare, con una forte concentrazione lungo gli Appennini, principale zona sismogenetica del Paese. L'ampiezza e la densità della rete sono fondamentali per ottenere misurazioni accurate dell'epicentro e della magnitudo, nonché per l'attivazione tempestiva dei sistemi di allerta.




Figure 6. Stazioni della Rete Sismica Nazionale

2.6. Impegno finanziario per la ricostruzione post-sismica

La Figura 7 illustra gli stanziamenti pubblici destinati alla ricostruzione a seguito dei principali terremoti italiani, dal Belice (1968) al Centro Italia (2016). L'Irpinia si conferma ancora una volta come l'evento più oneroso in termini economici, a causa dell'estensione dei danni e della complessità dell'intervento di ricostruzione. Questi dati evidenziano quanto i terremoti possano gravare sulle finanze pubbliche e rafforzano l'idea che investire in prevenzione sia non solo utile, ma anche economicamente vantaggioso nel lungo periodo.




Figure 7. Stanziamenti per Interventi di Ricostruzione in Italia

2.7. Analisi temporale della frequenza sismica

Le Figure 8 e 9 forniscono un'analisi della frequenza degli eventi sismici nel tempo, rispettivamente su base annua e decennale. La Figura 8 mostra il "Numero di terremoti" registrati annualmente dal 1985 al 2024. Si nota una variabilità interannuale con picchi evidenti in corrispondenza di sequenze sismiche importanti, come quelle del Centro Italia iniziate nel 2016. È visibile anche un trend generale di aumento del numero di eventi registrati negli anni più recente, attribuibile, almeno in parte, al potenziamento e all'incremento della sensibilità della Rete Sismica Nazionale. La Figura 9, similmente, traccia il "Numero di terremoti" aggregato per decennio. Questo grafico evidenzia in modo ancora più marcato l'incremento del numero di eventi sismici rilevati, specialmente negli ultimi decenni considerati.




Figure 8. Terremoti per Anno




Figure 9. Terremoti per Decennio

2.8. Distribuzione proporzionale degli eventi sismici per macro-area

La Figura 10 riassume la distribuzione percentuale degli eventi sismici nelle tre macro-aree italiane. Il Centro Italia si conferma l'area più attiva sismicamente, seguita dal Sud e infine dal Nord. Questa distribuzione è coerente con la geologia del Paese e con la maggiore instabilità tettonica che caratterizza la dorsale appenninica e le regioni meridionali.




Figure 10. Terremoti per Area

3. Un modello predittivo

L'evoluzione delle tecnologie di raccolta dati e delle tecniche di *machine learning* ha aperto nuove possibilità nel campo della sismologia, specialmente nella previsione dell'intensità degli eventi sismici. Sebbene sia ancora impossibile prevedere con precisione il momento e il luogo in cui si verificherà un terremoto, è possibile stimare la magnitudo potenziale sulla base di informazioni storiche e geografiche. In quest'ottica, il progetto ha portato alla realizzazione di un sistema end-to-end in grado di prevedere la magnitudo di un evento sismico, a partire dai dati grezzi fino all'inferenza automatizzata.

3.1. Preparazione Dati Preliminari

Il punto di partenza è stato un dataset storico di eventi sismici italiani, dal 1985 al 2025, proveniente da fonti ufficiali come l'INGV. I dati, originariamente in formato CSV, sono stati sottoposti a un processo di pulizia e normalizzazione. Un'attenzione particolare è stata rivolta alla colonna "place", contenente descrizioni testuali dell'ubicazione dell'epicentro. Attraverso espressioni regolari, queste descrizioni sono state strutturate in componenti numeriche e categoriali (distanza, direzione, località, sigla provinciale).

Inoltre, la colonna temporale è stata convertita in formato standardizzato per consentire l'estrazione di feature temporali, come mese, giorno della settimana e fascia oraria. Sono state eliminate le righe con valori mancanti in colonne essenziali, garantendo così un dataset coerente e utilizzabile per l'addestramento.

3.2. Feature Engineering

Una volta preparato il *dataset* di base, è stata intrapresa una fase cruciale di ingegneria delle *feature* per arricchire l'informazione disponibile al modello predittivo. Questa fase si articola nella creazione di diverse tipologie di *feature*:

1. Feature Geospaziali e Categoriali derivate:

- La profondità dell'ipocentro è stata categorizzata in classi discrete (superficiale, intermedia, profonda) basate su soglie standard. Questa trasformazione permette al modello di cogliere relazioni non lineari tra profondità e la magnitudo, trattando la profondità più come un fattore qualitativo che puramente quantitativo;
- La direzione cardinale è stata convertita in una rappresentazione angolare numerica (gradi). Per gestire la natura ciclica degli angoli (dove 359° sta a 0°), questi sono stati ulteriormente trasformati nelle

componenti *seno* e *coseno*. Tale *encoding* evita che il modello interpreti erroneamente la vicinanza tra angoli estremi (es. Nord e Nord-Ovest) e permette di rappresentare la direzionalità in modo continuo e periodico;

- Analogamente, le coordinate geografiche (latitudine e longitudine) sono state convertite da gradi a radianti e poi trasformate nelle loro componenti *seno* e *coseno*, per fornire al modello una rappresentazione più flessibile delle relazioni spaziali;
- La distanza in chilometri dalla località di riferimento è stata mantenuta e, in aggiunta, è stata calcolata la sua versione al quadrato, per permettere al modello di catturare eventuali effetti non lineari della distanza.

2. Feature Temporali:

- Dalla colonna *datetime* sono state estratte componenti temporali granulari come l'anno, il mese, il giorno del mese, il nome del giorno della settimana e l'ora dell'evento;
- È stata creata una *feature* binaria per indicare se l'evento si è verificato durante le ore notturne (es. dalle 22:00 alle 06:00);
- Il mese dell'anno è stato mappato a una categoria stagionale (inverno, primavera, estate, autunno);
- Per rappresentare la ciclicità del mese e dell'ora, anche queste variabili sono state trasformate nelle loro componenti seno e coseno, analogamente a quanto fatto per la direzione.

3. **Feature Dinamiche basate su Finestre Temporali:** Questa è una delle componenti più sofisticate dell'ingegneria delle *feature* implementata. Per ogni provincia, sono state calcolate metriche aggregate basate sull'attività sismica recente, specificatamente negli ultimi 30 e 7 giorni rispetto alla data di un potenziale evento. Queste includono:

- La magnitudo media degli eventi negli ultimi 30 giorni;
- Un trend della magnitudo negli ultimi 30 giorni, calcolato come il coefficiente angolare di una regressione lineare applicata alle magnitudo osservate in quel periodo. Questo fornisce un'indicazione se l'attività sismica sta aumentando o diminuendo in termini di intensità;
- Un rapporto di attività, definito come il numero di eventi negli ultimi 7 giorni diviso per il numero di eventi negli ultimi 30 giorni, per cogliere variazioni nell'intensità della frequenza sismica;
- La distanza in chilometri dell'ultimo evento registrato in quella specifica provincia.

Queste *feature* dinamiche sono state calcolate in modo da evitare il "*data leakage*"¹: per il set di sviluppo, sono state calcolate usando i dati fino alla data massima del set di sviluppo stesso; per il set di test, sono state calcolate usando esclusivamente i dati storici presenti nel set di sviluppo, garantendo che il modello non avesse accesso a informazioni future durante la sua valutazione. Le righe per cui non era possibile calcolare queste medie (es. nessuna attività nei 30 giorni precedenti in una provincia) sono state opportunamente gestite, ad esempio scartandole.

Infine, il *dataset*, arricchito con tutte queste nuove *feature*, è stato ordinato cronologicamente e suddiviso in un set di sviluppo (85% dei dati) e un set di test (15% dei dati). Questa suddivisione temporale è cruciale per valutare realisticamente le prestazioni del modello su dati futuri non visti. I due *dataset* risultanti sono stati salvati per le fasi successive.

3.3. Pipeline e Architettura del Modello

Con i dati preparati e arricchiti, il passo successivo è stato definire una pipeline di *preprocessing* robusta e selezionare un'architettura di modello adeguata.

1. **Selezione delle Feature:** Dai *dataset* di sviluppo e test, è stata selezionata un sottoinsieme specifico di *feature* considerate più rilevanti per la modellazione. Il target, la magnitudo, è stato isolato. Il set di sviluppo è stato ulteriormente suddiviso in un set di addestramento e un set di validazione (circa 82.35% *training*, 17.65% *validation* rispetto al *dev_data*). Questa suddivisione è essenziale: il set di addestramento viene usato per "insegnare" al modello, mentre il set di validazione serve per ottimizzare gli iperparametri e monitorare l'*overfitting* durante l'addestramento, senza "contaminare" la valutazione finale che avverrà sul set di test;

¹Divulgazione non autorizzata di informazioni sensibili da parte di un'organizzazione, spesso in modo involontario.

2. **Pipeline di Preprocessing:** È stata costruita una pipeline di trasformazione utilizzando `ColumnTransformer` di *scikit-learn*. Questo strumento permette di applicare trasformazioni diverse a sottoinsiemi specifici di colonne, garantendo coerenza e riproducibilità. La pipeline definita includeva:

- **Scaling Numerico:** Le *feature* numeriche continue (es. latitudine, longitudine, profondità, km, medie e trend di magnitudo, ecc.) sono state standardizzate tramite *StandardScaler*. Questa trasformazione (media zero e varianza unitaria) è benefica per molti algoritmi, inclusi quelli basati su gradienti come *XGBoost*, aiutando la convergenza e prevenendo che *feature* con ordini di grandezza diversi dominino il processo di apprendimento;
- **Encoding Catoriale:** Per le *feature* categoriali ad alta cardinalità, come la province, è stato utilizzato un *TargetEncoder*. Questo *encoder* sostituisce ogni categoria con una stima della media del target (magnitudo) per quella categoria, regolarizzata da un parametro di *smoothing* per mitigare l'*overfitting* su categorie poco frequenti;
- **Encoding Catoriale:** Per *feature* categoriali nominali con bassa cardinalità, come season e depth_category, è stato applicato *OneHotEncoder*. Questo crea nuove colonne binarie per ogni categoria, evitando di imporre un ordine artificiale. È stata configurata la gestione dei valori sconosciuti ("ignore"), rendendo il preprocessor più robusto a nuove categorie che potrebbero apparire in fase di inferenza;
- **Feature Cicliche:** Le *feature* già trasformate in componenti seno e coseno (es. direction_angle_sin, month_cos) sono state passate attraverso la pipeline senza ulteriori modifiche (passthrough), poiché già opportunamente codificate;
- Tutte le altre *feature* non specificate sono state anch'esse passate inalterate.

Una volta definita, questa pipeline di *preprocessing* è stata addestrata (`fit_transform`) sui dati di training (`X_train`, `y_train`) e poi utilizzata per trasformare (`transform`) i dati di validazione (`X_val`) e di test (`X_test`). Crucialmente, il preprocessor addestrato è stato serializzato (salvato su disco tramite `joblib`), permettendo il suo riutilizzo identico in fasi successive, come l'inferenza su nuovi dati.

3. **Scelta del Modello:** Per il compito di regressione della magnitudo, è stato scelto il modello *XGBoost*². *XGBoost* è un algoritmo di ensemble learning basato su alberi decisionali, noto per le sue elevate prestazioni, la capacità di gestire dati eterogenei (numerici e categoriali, sebbene qui le categoriali siano pre-processate), la robustezza all'*overfitting* grazie a meccanismi di regolarizzazione integrati (L1 e L2), e l'efficienza computazionale. È stato configurato per l'obiettivo di regressione (`reg:squarederror`) e per utilizzare la RMSE³ come metrica di valutazione durante l'addestramento.

3.4. Ottimizzazione degli Iperparametri e Addestramento

Per massimizzare le prestazioni del modello *XGBoost*, è stata condotta un'attenta ottimizzazione degli iperparametri, seguita dall'addestramento del modello finale.

1. **Strategia di Ottimizzazione Iperparametrica:** È stata impiegata una strategia di ricerca iperparametrica, probabilmente una combinazione di `RandomizedSearchCV` per un'esplorazione ampia dello spazio degli iperparametri e/o `GridSearchCV` per una ricerca più fine in regioni promettenti:

- Lo spazio di ricerca includeva iperparametri chiave di *XGBoost* come il tasso di apprendimento (`learning_rate`), la profondità massima degli alberi (`max_depth`), il peso minimo dei nodi figli (`min_child_weight`), le frazioni di campionamento di righe (`subsample`) e colonne (`colsample_bytree`), il parametro gamma per il controllo della complessità, i coefficienti di regolarizzazione L1 (`reg_alpha`) e L2 (`reg_lambda`), e il numero massimo di bin per la discretizzazione delle *feature* continue (`max_bin`);
- La ricerca è stata condotta utilizzando la validazione incrociata (K-Fold Cross-Validation, con 5 fold) sui dati di addestramento trasformati. Questo approccio garantisce che la stima delle prestazioni per ogni combinazione di iperparametri sia robusta e meno dipendente da una singola suddivisione train/validation;

²eXtreme Gradient Boosting

³Root Mean Squared Error

- Come metrica di ottimizzazione è stata utilizzata la "neg_root_mean_squared_error", che si cerca di massimizzare (equivalente a minimizzare l'RMSE);
 - Durante l'addestramento di ogni modello candidato all'interno della ricerca, è stato utilizzato il set di validazione (`X_val_tr`, `y_val`) per il monitoraggio delle prestazioni e per l'eventuale applicazione di meccanismi di "early stopping" (interruzione anticipata dell'addestramento se le prestazioni sul set di validazione smettono di migliorare), al fine di prevenire l'overfitting.
2. **Identificazione dei migliori Iperparametri:** Al termine del processo di ricerca, è stata identificata la combinazione di iperparametri che ha prodotto il miglior punteggio medio di RMSE in cross-validation. Questi iperparametri "ottimali" (nel codice, sembra che una specifica combinazione sia stata identificata e poi hardcodata, presumibilmente come risultato di una precedente fase di ricerca) sono stati selezionati per l'addestramento del modello finale;
 3. **Addestramento del Modello Finale:** Un nuovo modello XGBoost è stato inizializzato con i migliori iperparametri identificati. Questo modello è stato quindi addestrato sull'intero set di addestramento trasformato (`X_train_tr`, `y_train`). Anche in questa fase, è stato utilizzato il set di validazione trasformato (`X_val_tr`, `y_val`) per monitorare le curve di apprendimento e potenzialmente applicare l'early stopping, sebbene l'obiettivo primario fosse addestrare il modello con la configurazione ottimale. Il numero di stimatori (alberi) è stato fissato a un valore elevato (es. 1000), affidandosi all'early stopping o alla natura del processo di boosting per determinare il numero effettivo di alberi utili;
 4. **Salvataggio del Modello:** Una volta completato l'addestramento, il modello XGBoost finale è stato serializzato e salvato su disco (tramite joblib). Questo passaggio è fondamentale per la persistenza del modello, consentendo di caricarlo e utilizzarlo in futuro per effettuare previsioni su nuovi dati senza dover ripetere l'intero processo di addestramento e ottimizzazione.

3.5. Valutazione del Modello e Sistema di Previsione

Dopo l'addestramento e l'ottimizzazione, il modello finale è stato sottoposto a una valutazione rigorosa utilizzando il set di test, che non era stato impiegato in nessuna fase precedente dell'addestramento o della selezione degli iperparametri. Successivamente, è stato implementato un sistema per utilizzare il modello addestrato per effettuare previsioni:

1. **Valutazione sul Set di Test:** Il modello XGBoost addestrato è stato utilizzato per generare previsioni di magnitudo sul set di test trasformato (`X_test_tr`). Le prestazioni del modello sono state quindi valutate confrontando le magnitudo predette (`y_pred_xgb`) con le magnitudo reali (`y_test`). La metrica principale utilizzata per questa valutazione è stata il coefficiente di determinazione R^2 (R-squared). L' R^2 misura la proporzione della varianza nella variabile dipendente (magnitudo) che è prevedibile dalle variabili indipendenti (le *feature*). Un valore di R^2 più vicino a 1 indica una migliore capacità del modello di spiegare la variabilità dei dati. Questa valutazione sul set di test fornisce una stima imparziale di come il modello si comporterebbe su dati nuovi e non visti.
2. **Implementazione di un Sistema di Previsione:** Per dimostrare l'applicabilità del sistema, è stata sviluppata una funzione (`predict_magnitude`) che incapsula l'intero processo di inferenza. Questa funzione accetta in input un dizionario contenente le *feature* di un nuovo evento sismico (o di un ipotetico evento per cui si desidera una previsione). All'interno di questa funzione:
 - Viene caricato il preprocessor serializzato;
 - Viene caricato il modello XGBoost addestrato;
 - Il dizionario di input viene convertito in un DataFrame pandas, strutturato in modo coerente con i dati utilizzati durante l'addestramento;
 - Il preprocessor caricato viene utilizzato per applicare le stesse trasformazioni (scaling, encoding, ecc.) al DataFrame di input. Questo garantisce che i dati presentati al modello in fase di inferenza abbiano la stessa distribuzione e formato di quelli su cui è stato addestrato;
 - Infine, il modello XGBoost caricato effettua la previsione della magnitudo sui dati preprocessati;
 - La funzione restituisce il valore di magnitudo previsto.

L'esistenza di questa funzione, insieme a un esempio di dati di input, illustra come il sistema completo possa essere integrato in applicazioni più ampie o utilizzato per analisi "what-if", fornendo previsioni di magnitudo basate su un insieme specifico di caratteristiche dell'evento.

4. Data Storytelling: Rischio sismico italiano

L'analisi quantitativa e la modellazione predittiva, pur fondamentali possono talvolta mascherare la dimensione umana e narrativa intrinseca ai fenomeni complessi come la sismicità. Per ovviare a ciò e per comunicare più efficacemente la portata del lavoro svolto, abbiamo adottato un approccio di *data storytelling*. Questa metodologia permette di inquadrare i dati non come mere statistiche, ma come elementi di una narrazione strutturata, con protagonisti, obiettivi, ostacoli e potenziali risoluzioni.

4.1. I personaggi della nostra storia

Nella narrazione della sismicità italiana attraverso i dati, possiamo identificare i seguenti ruoli archetipici:

- **L'eroe:** In questa storia, l'eroe può essere interpretato come il **territorio italiano stesso** (o "Italia Sismica" come entità), intrinsecamente dinamico e soggetto a forze naturali. L'eroe non è un'entità volitiva nel senso tradizionale, ma il soggetto centrale attorno a cui si sviluppa la narrazione;
- **L'oggetto del desiderio:** L'aspirazione fondamentale, l'oggetto del desiderio dell'eroe (e implicitamente della società che lo abita), è la **resilienza**: la capacità di coesistere con il fenomeno sismico minimizzandone le conseguenze distruttive. In termini più concreti, il desiderio è che gli eventi sismici non si traducano in perdite umane, danni economici ingenti e disgregazione del tessuto sociale e culturale;
- **Il problema:** Il problema centrale, la sfida che l'eroe deve affrontare, è la **vulnerabilità intrinseca del territorio e delle sue comunità**. Nonostante il desiderio di resilienza, la realtà storica e attuale, come documentato nelle sezioni precedenti (cfr. Capitolo 2), dimostra che i terremoti continuano a infliggere ferite profonde, causando vittime, sfollati, e ingenti costi economici e sociali;
- **L'antagonista:** L'antagonista principale non è il terremoto in sé, che è una manifestazione naturale, quanto piuttosto la **combinazione di fattori che amplificano la sua capacità distruttiva**. Questo include la **fragilità del patrimonio edilizio** (es. edifici fragili), una pianificazione territoriale talvolta inadeguata, e le lacune nella preparazione e nella prevenzione che rendono le comunità più esposte;
- **Il sidekick:** Il ruolo del *sidekick*, ovvero il supporto umano e tecnico che affianca l'eroe nella comprensione e gestione del problema, è duplice. Da un lato, troviamo gli **esperti e le istituzioni scientifiche** (come l'INGV), che forniscono i dati, le analisi e gli strumenti per comprendere il fenomeno sismico (cfr. Capitolo 1). Dall'altro, le **comunità locali e i cittadini** che, con la loro esperienza diretta e la loro resilienza quotidiana, incarnano la risposta umana alla sfida sismica e sono i diretti beneficiari di una gestione più efficace del rischio.

4.2. La struttura narrativa

La narrazione della sismicità italiana, così come presentata in questo lavoro e idealmente trasposta in una piattaforma web interattiva, può essere articolata secondo la classica struttura in tre atti:

1. **Atto Primo: Il Setup** Questa fase iniziale stabilisce il contesto storico-geografico del fenomeno sismico in Italia. Corrisponde alle sezioni del nostro studio che illustrano l'acquisizione dei dati (cfr. Capitolo 1) e le analisi sulla distribuzione spaziale e temporale degli eventi sismici (es. Figure 3, 4, 5, 6, 8, 9). Una pagina web dedicata potrebbe visualizzare questi aspetti attraverso mappe interattive della sismicità storica e recente, grafici sui trend temporale e sulla densità degli eventi per regione. L'obiettivo è introdurre l' "universo" della storia, presentando il protagonista (Italia Sismica) e la natura della sua sfida.
2. **Atto Secondo: L'Evidenza del problema** In questo atto, il problema emerge in tutta la sua gravità. Si esplorano le conseguenze dirette e indirette dei terremoti, mettendo in evidenza l'impatto demografico (cfr. Capitolo 2.1, Figura 1), socio-economico (cfr. Capitolo 2.2, Figura 2) e il fardello finanziario della ricostruzione (cfr. Capitolo 2.6, Figura 7). Qui, il desiderio dell'eroe di evitare danni si scontra con la realtà della sua vulnerabilità e con l'azione dell'antagonista (la fragilità infrastrutturale). La tensione narrativa aumenta mostrando la portata delle perdite e delle difficoltà.

3. **Atto Terzo: Verso una possibile soluzione** Il terzo atto introduce una possibile via d'uscita o, quantomeno, uno strumento per affrontare più efficacemente il problema. Nel nostro caso, questo è rappresentato dallo sviluppo di un **modello predittivo per la stima della magnitudo** (cfr. Capitolo 3). Pur con la consapevolezza che la previsione esatta dei terremoti rimane difficilmente raggiungibile, questo modello simboleggia il tentativo proattivo di utilizzare la conoscenza (i dati e il *machine learning*) per migliorare la comprensione del rischio e, potenzialmente, informare strategie di mitigazione e prevenzione più efficaci. Questo atto offre una prospettiva di speranza e di *empowerment*, mostrando come l'ingegno umano e la tecnologia possano contribuire a ridurre la vulnerabilità.

Attraverso questa lente narrativa, il presente lavoro non si limita a esporre dati, ma cerca di costruire una storia comprensibile e significativa sul rapporto complesso tra l'Italia e i suoi terremoti, sottolineando le sfide, ma anche le potenzialità insite in un approccio informato e tecnologicamente avanzato.

5. Conclusioni

L'Italia è da sempre un territorio ad alta sismicità, dove la convivenza con il rischio sismico rappresenta una sfida complessa e multidimensionale. In questo lavoro, abbiamo cercato di affrontare tale sfida attraverso una prospettiva integrata, che unisce l'acquisizione automatizzata di dati, la visualizzazione analitica e lo sviluppo di strumenti predittivi basati su modelli di *machine learning*.

Nella prima fase, è stato progettato e implementato un sistema software modulare per l'estrazione continua e strutturata dei dati sismici resi disponibili dall'INGV. Tale sistema, costruito secondo principi di scalabilità e resilienza, costituisce una solida base per qualsiasi tipo di analisi successiva. La fase di visualizzazione ha permesso di esplorare e rappresentare l'impatto dei terremoti sul territorio nazionale, evidenziandone le conseguenze demografiche, economiche e culturali, così come le dinamiche spaziali e temporali. Le visualizzazioni prodotte non solo rendono più accessibili e interpretabili i dati grezzi, ma forniscono anche un supporto concreto alla comunicazione del rischio e alla sensibilizzazione pubblica. Infine, lo sviluppo di un modello predittivo per la stima della magnitudo ha dimostrato come i dati storici e il *machine learning* possano essere integrati per costruire strumenti di analisi preventiva. Il modello, basato su XGBoost, ha mostrato buone capacità di generalizzazione e può essere facilmente adattato a scenari operativi, grazie alla pipeline di *preprocessing* automatizzata e alla funzione di inferenza integrata. Nonostante i risultati incoraggianti, è importante sottolineare i limiti intrinseci di qualsiasi approccio predittivo applicato a fenomeni complessi e non deterministici come i terremoti.

In un contesto in cui l'accesso ai dati è sempre più ampio e le tecnologie predittive sempre più sofisticate, il ruolo del data journalism e della modellazione diventa centrale nel costruire consapevolezza e supportare decisioni informate. Coniugare rigore scientifico, capacità comunicativa e innovazione tecnologica è, oggi più che mai, la chiave per affrontare con efficacia i rischi naturali che interessano il nostro territorio.